S&P 500 Endeksinin Yön Tahminine Yönelik İleri Beslemeli Derin Sinir Ağı Yaklaşımı

Özet

Bu çalışmada S&P 500 sektör ETF'lerinin T+5 iş günü sonrası fiyat yönü (yükseliş / düşüş) tahmin edilmiş; problem ikili sınıflandırma olarak modellenmiştir. Veri seti yaklaşık 257.603 günlük gözlemden oluşmakta, eksik değer temizliği ve T+5 hedef etiketinin üretilmesinin ardından 236.377 örnekleme indirgenmiştir. Modelin girdisi finansal teknik analizde yaygın olan dokuz göstergeden oluşturulmuştur: logaritmik getiri, 10/30 günlük volatilite, RSI(14), MACD, sinyal, histogram ve Bollinger Bantları (alt ve üst).

Mimari şu şekilde: Dense(64, ReLU) → Dropout(0,5) → Dense(32, ReLU) → Dropout(0,5) → Dense(1, Sigmoid); toplam yalnızca 2.753 öğrenilebilir parametre. Eğitim Adam optimizatörü ve binary crossentropy kayıp fonksiyonu ile, 64 mini-batch ve EarlyStopping patience 20,altında gerçekleştirilmiş; veri sızıntısını önlemek için train/test ayrımı shuffle=False ile yapılmış ve StandardScaler yalnızca eğitim setine fit edilmiştir.

Test setinde elde edilen sonuçlar; kayıp 0,6866 ve doğruluk %55,84'tir. ROC-AUC değeri 0,514 olarak ölçülmüştür. Eğitim ve doğrulama kayıplarının (sırasıyla 0,6877 ve 0,6845) yakın seyretmesi, mimarinin aşırı öğrenmediğini; sigmoid çıktılarının 0,50–0,55 aralığında yoğunlaşması ise mevcut özelliklerle ulaşılabilecek sinyal sınırına yakınsadığını göstermektedir.

1. Giriş ve Problem Tanımı

Finansalpiyasalar; makrohaberler,likidite şokları, sektör rotasyonu ve davranışsal etmenlerin süperpozisyonu olarak ortaya çıkan, doğrusal olmayan dinamik sistemlerdir. Bu nedenle anlamlı sonuç veren desen yakalamak çok zordur rastgele tahmin tabanı yaklaşık %50'dir. Tahmin probleminin biçimsel ifadesi şudur: t anındaki gözlem vektörü $x \in \mathbb{R}_t$ verildiğinde, beş iş günü sonraki kapanış fiyatının bugünkü kapanışın üzerine çıkıp çıkmayacağını gösteren ikili $y_t \in \{0, 1\}$ hedefini tahmin etmek. Hedef değişken,

$$yt = [\ \text{Fiyat}(T+5) > \text{Fiyat}(T)\ ]$$

2. Veri Seti ve Özellik Kümesi

2.1. Veri Setinin Yapısı

Çalışmada kullanılan sp500_deep_learning_massive_data.csv dosyası 257.603 satır ve 15 sütundan oluşmaktadır. Her satır, S&P 500 sektör ETF'lerine ait belirli bir hissenin belirli bir makro olay penceresindeki günlük gözlemini temsil eder. Veri seti; tarih, olay ismi, hisse, grup, T0'a göreceli gün, düzeltilmiş kapanış fiyatı ve dokuz teknik gösterge sütunundan oluşmaktadır.

2.2. Hedef Değişkenin Üretimi

Hedef değişken Hedef ∈ {0, 1}, [Olay_Ismi, Hisse] gruplarında kapanış fiyatının beş iş günü ileri kaydırılmasıyla (shift(-5)) hesaplanmıştır. Gruplama önemlidir; farklı olay-hisse ikilileri arasındaki sınır geçişlerinde T+5 değerinin başka bir seriden çekilmesi modeli yanıltır. Beşinci günden sonraki gözlemler için T+5 tanımsızdır; bu satırlar (toplam 21.226) NaN temizliği aşamasında çıkarılmıştır. Eğitim setinin %54,2'si, test setinin %54,7'si yükseliş sınıfına aittir; veride hafif bir sınıf dengesizliği bulunmaktadır.

2.3. Özellik Kümesi

Modelin girdi vektörü, üç farklı bilgi sınıfını temsil eden dokuz teknik göstergeden oluşmaktadır: getiri tabanlı (Log Getiri), volatilite tabanlı (10g, 30g volatilite), momentum tabanlı (RSI, MACD ailesi) ve bant tabanlı (Bollinger).

Özellik	Açıklama
Log_Getiri	Kapanış fiyatının logaritmik günlük getirisi
Volatilite_10g	10 işlem günü pencereli oynaklık
Volatilite_30g	30 işlem günü pencereli oynaklık
RSI_14	14 günlük Göreceli Güç Endeksi (momentum)
MACD_12_26_9	12-26 günlük EMA farkı (trend & momentum)
MACDh_12_26_9	MACD histogramı (momentum ivmesi)
MACDs_12_26_9	MACD'nin 9 günlük EMA'sı (sinyal çizgisi)
BBL_20_2.0	Bollinger alt bandı (20g, 2σ)
BBU_20_2.0	Bollinger üst bandı (20g, 2σ)

Tablo 1. Modelin girdisini oluşturan dokuz teknik gösterge.

2.4. Veri Sızıntısının Önlenmesi Finans gibi zaman serisinin önemli olduğu konularda veri sızıntısına dikkat edilmeli. Eğer veriler rastgele

• shuffle=False: train_test_split ile veri seti kronolojik olarak ilk %80'i (189.101 satır) eğitim, son %20'si (47.276 satır) test bloğu olarak ayrılmıştır.

• Leakage-safe scaling: StandardScaler nesnesi yalnızca eğitim setine fit edilmiş; test seti için yalnızca transform çağrısı kullanılmıştır. Eğitim setinden hesaplanan ortalama ve standart sapma test setine uygulanır; geleceğin istatistiksel yapısı geçmişe taşınmaz.

Pipeline'ın sonucu
Bu iki tedbir bir arada raporlanan başarım metriklerinin gerçekçi olmasını sağlar; modelin gördüğü test seti, eğitim sırasında modele hiçbir biçimde sızdırılmamıştır.

3. Model Mimarisi ve Teknik Altyapı

3.1. Tasarım İlkesi

Modelin tasarımı, derin öğrenmenin temel kavramsal akışını izlemektedir: Perceptron (atomik birim) → Dense (tam-bağlı) katman → Çok katmanlı ileri beslemeli ağ. Tek bir nöron $y = \sigma(W \cdot x + b)$ biçiminde, ağırlıklı girdilerin doğrusal birleşimini bir aktivasyon fonksiyonundan geçirir. Aynı katmanda paralel dizilmiş çok sayıda nöron Dense katmanını, ardışık Dense katmanlarının üst üste yığılması ise derin ileri beslemeli sinir ağını oluşturur. Mimari kasıtlı olarak sade tutulmuştur.

3.2. Katman Yapısı

Katman	Çıktı Şekli	Aktivasyon / İşlev	Parametre
Input	(None, 9)	Girdi vektörü	0
Dense	(None, 64)	ReLU	640
Dropout	(None, 64)	Rate = 0,5	0
Dense	(None, 32)	ReLU	2.080
Dropout	(None, 32)	Rate = 0,5	0
Dense	(None, 1)	Sigmoid	33
Toplam	**—**	**—**	**2.753**

Tablo 2. İleri beslemeli modelin katman bazlı özeti.

Toplam 2.753 öğrenilebilir parametre, finansal zaman serisi standartlarında oldukça hafif bir modeldir. Hafifliğin gerekçesi iki yönlüdür: birincisi, finansal verinin düşük sinyal-gürültü oranı yüksek kapasiteli modellerin gürültüyü ezberleme eğilimini güçlendirir; ikincisi sade bir mimari, ileride denenecek mimarilerin getireceği marjinal kazanımın dürüst biçimde ölçülmesini mümkün kılar.

3.3. Aktivasyon ve Optimizasyon Tercihleri

- ReLU (gizli katmanlar): $\mathrm{ReLU}(x) = \max(0, x)$. Sıfırın altındaki sinyali kırpıp türevlenebilir kalır; seyrek aktivasyon sağlar ve gradyan kaybolması (vanishing gradient) sorununu sigmoid/tanh'a kıyasla büyük ölçüde hafifletir.
- Sigmoid (çıkış katmanı): $\sigma(z) = 1 / (1 + e^{-z})$. Gerçek sayıyı (0, 1) aralığına sıkıştırarak ikili sınıflandırma için doğrudan olasılık yorumu sağlar.
- Adam optimizatörü: Momentum ve uyarlanabilir öğrenme oranlarını birleştirir; rejim değişikliği sergileyen finansal verilerde sağlam bir varsayılan tercihtir.
- Binary Crossentropy: $L = -[\, y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y}) \,]$. Modelin yanlış sınıfa yüksek olasılık vermesini logaritmik biçimde cezalandırır.

3.4. Aşırı Öğrenmeyi Önleme Stratejileri

- Dropout (rate = 0,5): Her ileri geçişte gizli katman nöronlarının yarısı rastgele kapatılır. Etkili biçimde her mini-batch için farklı bir alt-ağ eğitilmiş olur; öğrenilen temsiller belirli nöron eş-zamanlılıklarına bağımlı olmaktan çıkar.
- EarlyStopping (patience = 10): Doğrulama kaybı 10 ardışık epoch boyunca iyileşmediğinde eğitim durdurulur ve en iyi val_loss değerine sahip ağırlıklar geri yüklenir. Bu çalışmada eğitim 12. epoch'ta sonlanmıştır.
- Mini-batch boyutu = 64: Tam-batch yerine küçük yığınlarla optimizasyon, gradyana faydalı bir gürültü ekleyerek dar yerel minimumlara takılma olasılığını azaltır.
- Tekrarlanabilirlik: NumPy ve TensorFlow rastgelelik tohumları 42 olarak sabitlenmiştir.

4. Eğitim Süreci ve Test Sonuçları

4.1. Eğitim Süreci

Eğitim, EarlyStopping mekanizması nedeniyle 12. epoch'ta sonlanmıştır. Son epoch'ta eğitim kaybı 0,6877, doğrulama kaybı 0,6845 olarak ölçülmüştür. İki kayıp arasındaki fark 0,0032 mutlak değerdir; eğitim ve doğrulama kayıpları pratik olarak aynı seviyede ilerlemiş, modelde anlamlı bir aşırı öğrenme gözlenmemiştir. Eğitim doğruluğu yaklaşık %54'ten %55 civarına yükselirken, doğrulama doğruluğu ilk epoch'tan itibaren ~%57–%58 bandında dalgalanmıştır.

Kayıp eğrisinin bu denli erken düzleşmesi iki olası açıklama içerir: (i) modelin kapasitesi mevcut özelliklerden çıkarılabilecek sinyali yakalamıştır, (ii) ek öğrenme yalnızca sinyalden değil, gürültüden de kaynaklanabilir ve EarlyStopping bu noktayı doğru tespit etmiştir. Pratikte bu iki açıklama birbirini dışlamaz.

4.2. Test Seti Üzerindeki Nihai Metrikler

Metrik	Değer
Test Kaybı (Binary Crossentropy)	0,6866
Test Doğruluğu (Accuracy)	%55,84
ROC – AUC	0,514
Eğitim Kaybı (son epoch)	0,6877
Doğrulama Kaybı (son epoch)	0,6845
Eğitim Süresi (epoch)	12
Toplam Parametre	2.753

Tablo 3. Test seti üzerinde elde edilen başarım metrikleri.

4.3. Karışıklık Matrisi

Karışıklık matrisi incelendiğinde, modelin yükseliş (1) sınıfına belirgin biçimde meyilli olduğu görülmektedir.

	Tahmin: Düşüş (0)	Tahmin: Yükseliş (1)	Toplam
Gerçek: Düşüş (0)	1.481	19.925	21.406
Gerçek: Yükseliş (1)	951	24.919	25.870
Toplam	**2.432**	**44.844**	**47.276**

Tablo 4. Test seti karışıklık matrisi.

Yükseliş sınıfı için duyarlılık (recall) %96,3 ile çok yüksek; düşüş sınıfı için ise yalnızca %6,9 düzeyindedir. Bu desen, sınıf dağılımının %54,7 yükseliş yönlü olması ve karar eşiğinin sabit 0,50'de tutulmasının birleşik bir sonucudur. Karar eşiğinin uygulamaya göre yeniden ayarlanması (örneğin 0,55) farklı bir kesinlik-duyarlılık dengesine yol açacaktır.

5. Sonuçların Yorumlanması

5.1.ROC – AUCAnalizi

ROC eğrisi yaklaşık 45° köşegen üzerinde uzanmakta; AUC değeri 0,514 olarak hesaplanmıştır. AUC = 0,5 rastgele bir sınıflandırıcıyı, AUC = 1,0 mükemmel ayrıştırmayı temsil ettiğine göre, model rastgeleliğin biraz üzerinde, fakat sıfır olmayan bir ayrıştırma kapasitesine sahiptir. Bu, ileri beslemeli ağdan saf teknik göstergelerle çıkarılabilen sinyalin tabanını temsil etmektedir; sekans bilgisini açıkça modellenmediğinden finansal zaman serilerindeki değişim yakalanamamakta.

5.2. Sigmoid Olasılık Çıktısının Dağılımı

Modelin sigmoid çıktılarının test seti üzerindeki dağılımı, klasik bir yüksek-bilgili sınıflandıran beklenen iki kutuplu yapı yerine, 0,50–0,55 aralığında yoğunlaşan dar bir çan eğrisi sergilemektedir. Bir başka deyişle model, neredeyse hiçbir gözlemde 0,05 veya 0,95 gibi uç güven seviyelerine ulaşmamaktadır.

Bu sıkışmanın doğrudan açıklaması finansaldır: piyasa hareketi, modelin elindeki dokuz teknik gösterge tarafından belirlenmemekte; rastgelelik ve haber/likidite kaynaklı şoklar dağılımın kuyruğunu bastırmaktadır. Bu bulgunun pratik bir karşılığı, karar eşiğinin uygulamaya göre yeniden ayarlanmasıdır. 0,50 yerine 0,55 gibi daha kısıtlayıcı bir eşik, daha az ama daha güvenilir tahmin üretebilir.

5.3. Genel Değerlendirme

Sonuçlar bütüncül olarak şu üç bulguya işaret etmektedir:

- Mimari aşırı öğrenmemiştir: Eğitim ve doğrulama kayıplarının (0,6877 vs. 0,6845) tüm epoch'lar boyunca yakın seyretmesi, Dropout(0,5) ve EarlyStopping disiplininin etkin biçimde işlediğini göstermektedir.
- Model sinyal sınırına yakınsamıştır: %55,84 doğruluk ve 0,514 AUC, mevcut özellik kümesi ve sade Dense mimarisinin ulaşabileceği üst sınıra yakın görünmektedir; kapasiteyi artırmak yerine farklı bir bilgi kaynağı (sekans yapısı veya yeni özellikler) eklemek, başarımı esaslı biçimde değiştirebilir.
- Sınıf meyli yapısaldır: Modelin yükseliş sınıfına olan meyli, hem hafif sınıf dengesizliğinden hem de eşiğin sabit 0,50'de tutulmasından kaynaklanmaktadır; class_weight uygulanmamıştır.

6. Sonuç ve Gelecek Çalışmalar

6.1. Genel Sonuç

Bu çalışmada S&P 500 sektör ETF'lerinin T+5 günlük yön tahminine yönelik bir İleri Beslemeli (Feedforward) sinir ağı modeli geliştirilmiş ve sonuçları finansal zaman serisi tahmininin temel zorlukları çerçevesinde değerlendirilmiştir. Model; dokuz teknik göstergeden oluşan girdi vektörünü, Dense(64) → Dropout(0,5) → Dense(32) → Dropout(0,5) → Sigmoid mimarisi ile işlemektedir. Toplam 2.753 öğrenilebilir parametre, ~236 bin örneklem üzerinde Adam optimizatörü ve binary crossentropy kayıp fonksiyonu ile eğitilmiş; eğitim 12. epoch'ta EarlyStopping tarafından sonlandırılmıştır.

Test setinde %55,84 doğruluk ve 0,514 ROC-AUC değerleri elde edilmiştir. Eğitim ve doğrulama kayıplarının yakın seyretmesi mimarinin aşırı öğrenmediğini; sigmoid çıktılarının 0,50–0,55 aralığında yoğunlaşması ise modelin mevcut özelliklerle ulaşılabilecek sinyal sınırına yakınsadığını gösterdi.

6.2. Çalışmanın Katkıları

- Metodolojik disiplin: Train/test ayrımında shuffle=False ve scaler için yalnızca eğitim setinden fit yaklaşımı, finansal zaman serileri için zorunlu olan leakage-safe bir pipeline'ın somut uygulamasını sergilemektedir.
- Sade ama dürüst baseline: Toplam 2.753 parametreli mimari, daha karmaşık modellerin getireceği iyileşmenin ölçüleceği şeffaf bir referans noktası oluşturur.
- Tanı niteliğinde sigmoid analizi: Sıkışan olasılık dağılımının finansal yorumu, model çıktısını yalnızca doğruluk değil bilgi içeriği açısından da değerlendiren bir bakış sunmaktadır.

6.3. Sınırlılıklar

Çalışmanın sınırlılıkları şunlar: (i) mimari, geçmiş zaman adımlarına dair açık bir hafıza yapısı içermez ve her örneklemi bağımsız olarak işler; (ii) özellik kümesi yalnızca dokuz teknik göstergeyle sınırlıdır; harici endeks, hacim, makro değişken veya haber/duygu tabanlı özellikler dahil edilmemiştir; (iii) sınıf dengesizliği için class_weight uygulanmamıştır; (iv) karar eşiği tüm değerlendirmelerde sabit 0,50 olarak tutuldu.

6.4. Gelecek Çalışmalar

- Adım 1 — Kayan pencere ile 3D girdi: Aynı dokuz özellik, geçmiş k = {5, 10, 20} işlem gününü kapsayan kayan pencere içinde 3D tensör olarak yeniden düzenlenebilir; bu, sekans modellerinin doğal girdi formatıdır.
- Adım 2 — Sekans tabanlı mimariler: Simple RNN, LSTM ve GRU mimarileri, aynı veri kümesi üzerinde tutarlı biçimde karşılaştırılarak sekans bilgisinin getirdiği marjinal kazanım ölçülebilir.
- Adım 3 — Dikkat (Attention) ve Transformer: Self-attention tabanlı modeller, makro olay pencereleri içindeki bilgilendirici zaman adımlarına ağırlık vermeyi öğrenebilir; uzun bağımlılıklarda RNN ailesinin sınırlamalarını aşar.
- Adım 4 — Eşik kalibrasyonu ve işlem stratejisi: Karar eşiği, doğruluk yerine portföy beklentisi (Sharpe oranı, kümülatif getiri) hedef alınarak optimize edilebilir; model çıktısı bir işlem stratejisinin girdisine dönüştürülerek buy-and-hold karşılaştırması yapılabilir.
- Adım 5 — Özellik zenginleştirme: Hacim, sektörel rotasyon göstergeleri, makro değişkenler ve haber/duygu skorları girdiye eklenerek modelin bilgi tabanı genişletilebilir.

6.5. Kapanış

Sade bir ileri beslemeli mimari, S&P 500 yön tahmini gibi düşük sinyal-gürültü oranına sahip bir problemde başarımın üst sınırını vermez; ancak alt sınırını açıkça belirler. Bu rapor, %55,84 doğruluk ve 0,514 AUC değerlerini, ileride sekans ve dikkat tabanlı mimarilerin getireceği iyileşmenin ölçüleceği bir taban olarak kayda geçirmektedir.