Makroekonomik Şokların S&P 500 ETF'leri Üzerindeki Etki Analizi

BeratÖzkan • VeriBilimi Çalışması

Özet

Bu çalışma, beş önemli makroekonomik olayın ABD borsası üzerindeki etkisini incelemektedir olaylar şunlardır : 2016 ve 2024 ABD seçimleri, Mart 2020'de COVID-19'un piyasalara yansıması, Şubat 2022'de başlayan Rusya–Ukrayna Savaşı ve Nisan 2024'teki İsrail–İran gerilimi. Analizde on sektör ETF'i ile altın ve ham petrol ele alınarak olay çalışması yapıldı. T=0, [-3, +3] ve [-10, +10] pencerelerinde anormal getiri (AR), kümülatif anormal getiri (CAR) ve volatilite değişimleri hesaplanmış; sektör ortalamaları t-testi ile değerlendirilmiştir.

Sonuçlar, enerji (XLE) ve ham petrolün (CL=F) şoklara genellikle negatif tepki verdiğini, buna karşılık sağlık (XLV) ve finans (XLF) sektörlerinin daha dayanıklı olduğunu göstermektedir. Altını ise ele aldığımız 5 olay dahilinde 'güvenli liman ' algısının gerisinde .

Anahtar Kelimeler: olay çalışması, anormal getiri, kümülatif anormal getiri, sektör ETF, makroekonomik şok, volatilite, portföy yönetimi.

1. Giriş ve Literatür Taraması

Olay çalışması ; finansal bir varlığın getirisi, kamuoyuyla paylaşılan belirli bir haber veya makro olay etrafında "normal" düzeyinden istatistiksel olarak anlamlı bir biçimde sapıp sapmadığını öğrenmek için kullanılan, Fama vd. (1969) ile sistemleştirilen bir yöntemdir. Yöntemin temel mantığı; gözlenen getiriden, olayın olmadığı durumda piyasanın üreteceği "beklenen getiri"nin çıkarılarak elde edilen anormal getirinin, olay penceresi boyunca istatistiksel olarak test edilmesidir. Seçilen olaylar küresel olarak dünyayı etkileyen olaylar seçildi.

Örnek bir çalışma. Yürük (2022). Yazar, 24 Şubat 2022 tarihinde başlayan Rusya–Ukrayna savaşı ile Rus bankalarının SWIFT sisteminden çıkarılacağına dair AB Komisyonu duyurusunu iki ayrı olay olarak tanımlamış ve her iki olay için ±10 günlük olay penceresi kullanarak BİST 100 endeksindeki anormal getirileri Z-testi ve t-testi ile sınamıştır. Çalışmada, savaşın yalnızca taraflarını değil, Rusya ve Ukrayna ile yüksek ithalat–ihracat hacmine sahip Türkiye gibi ülkelerin borsalarını da istatistiksel olarak anlamlı düzeyde etkilediğini göstermiştir.

Literatürde olay çalışması, kurumsal yönetim derecelendirme notlarının açıklanması (Sakarya, 2011), siyasi seçimler ve referandumlar (Ada vd., 2013) ile iklim politikalarının enerji sektörü üzerindeki etkisi (Diaz-Rainey vd., 2021) gibi geniş bir alanda kullanılmıştır. Bu çalışma, anılan literatürü ABD piyasası ölçeğinde, sektör düzeyinde ve birden çok makro olayı karşılaştırmalı olarak ele alacak biçimde genişletmektedir.

2. Veri Seti ve Metodoloji

2.1. Olaylar ve Varlık Evreni

Çalışmada beş tane makroekonomik olay incelendi olaylar ve sektörler şu şekilde: 2016 ABD Başkanlık Seçimleri, COVID-19 pandemisi (sağlık/ekonomik), Rusya–Ukrayna Savaşı (jeopolitik), 2024 ABD Seçimleri ve İsrail–İran gerilimi (jeopolitik). Varlık evreni; teknoloji (XLK), finans (XLF), enerji (XLE), sağlık (XLV), savunma sanayi (ITA), temel tüketim (XLP), tüketici tercihine bağlı (XLY) ve gayrimenkul (XLRE) olmak üzere sekiz sektör ETF'i ile iki makro varlıktan (altın , ham petrol) oluşmaktadır. Piyasa genel hareketi gösterge endeks olarak SPY ETF'i ile temsil edilmiştir.

2.2. Olay Pencereleri

Üç farklı olay penceresi tanımlanmıştır: (i) anlık şok tepkisini yakalamak için **T = 0**, (ii) haberin kısa vadede sindirilmesini yakalamak için **[-3, +3]** ve (iii) olay öncesi sızıntı ile olay sonrası geciken tepkileri birlikte yakalamak için **[-10, +10]** günlük geniş penceredir. Bu çoklu pencere yapısı, Yürük (2022)'ün BİST 100 üzerinde uyguladığı [-10, 0], [-5, 0], [0, +5] ve [0, +10] CAAR pencereleri ile metodolojik olarak uyumludur.

2.3. Anormal Getiri, CAR ve Volatilite Şoku

Herhangi bir *i* sektörü ve *t* günü için **anormal getiri**, ilgili sektör getirisinden piyasanın genel hareketini temsil eden gösterge endeks (SPY) getirisinin çıkarılmasıyla hesaplanmıştır:$\mathbf{AR_{i,t} = R_{i,t} - SPY,t.R}$
Bu yaklaşım, Yürük (2022)'ün $R_{i,t}$ üzerinden tahmin dönemi ortalamasını çıkararak elde ettiği AR ile aynı mantığı taşımakta.

Olayların etkileri tek bir günle sınırlı değildir, günlük AR değerleri olay penceresi boyunca toplanarak **kümülatif anormal getiri** elde edildi: $\mathbf{CAR_i[T_1, T_2] = \Sigma\ AR_{i,t}}$. Volatilite şoku ise her sektör için 10 günlük hareketli standart sapma kullanılarak ölçülmüştür; fiyat *belirsizliği* üzerindeki etkiyi de raporlamayı sağlamaktadır.

2.4. İstatistiksel Testi

Sektör bazlı ortalama CAR değerlerinin sıfırdan farklı olup olmadığı **tek-örneklem t-testi** ile sınanmıştır (H_0: ortalama CAR = 0). Bu tercih, Yürük (2022) çalışmasında AR ve Kümülatif Ortalama Anormal Getiri (CAAR) değerlerinin istatistiksel anlamlılığının t-testi ile ölçülmesi yaklaşımını ABD sektör örneklemine uyarlamaktadır.

Olay × Sektör	CAR[-3,+3]	Yorum
COVID-19 × XLE (Enerji)	−17.8%	Küresel kapanma kaynaklı talep şoku
COVID-19 × CL=F (Ham Petrol)	−16.4%	Petrol talebinin sert biçimde çökmesi
2016 Seçim × XLF (Finans)	+6.9%	Faiz/regülasyon beklentili yukarı tepki
2016 Seçim × ITA (Savunma)	+6.2%	Savunma harcaması beklentisinin fiyatlanması
COVID-19 × XLV (Sağlık)	+3.0%	Defansif sektör karakterinin doğrulanması
2016 Seçim × GLD (Altın)	−9.7%	"Güvenli liman" beklentisinin altında kalış

Tablo1.Olay × Sektörmatrisindeöneçıkanaltıkombinasyon(CAR[-3,+3]).

3. İstatistiksel Testler ve Bulgular

3.1. Sektör Bazlı Ortalama CAR ve t-Testi

Beş olay üzerinden sektör bazlı ortalama CAR[-3, +3] Tablo 2'de raporlanmıştır. Pozitif ortalama ile en güçlü ayrışma finans (XLF, +1.6%) ve sağlık (XLV, +1.2%) sektörlerinde gözlenirken; ham petrol (CL=F, −4.3%), enerji (XLE, −3.5%) ve altın (GLD, −2.6%) negatif yönde ayrışmıştır. Beş tane olaya bakıldığından dolayı p testi anlamlı sonuç vermedi.

Sektör (Ticker)	Ort. CAR[-3,+3]	p-değeri	Sektör (Ticker)	Ort. CAR[-3,+3]	p-değeri
Finans (XLF)	+1.6%	0.331	Tük. T. Bağlı (XLY)	−0.7%	0.551
Sağlık (XLV)	+1.2%	0.337	Gayrimenkul (XLRE)	−1.4%	0.432
Savunma (ITA)	+0.5%	0.892	Temel Tük. (XLP)	−1.7%	0.512
Teknoloji (XLK)	+0.3%	0.872	Altın (GLD)	−2.6%	0.347
Enerji (XLE)	−3.5%	0.390	Ham Petrol (CL=F)	−4.3%	0.240

Tablo2.Sektörbazlı ortalamaCAR[-3, +3]değerlerivetek-örneklemt-testip-değerleri(5 olayüzerinden).

Olay Penceresi	Yürük (2022) — BİST 100 Rusya-Ukrayna	Bu çalışma — S&P 500 Enerji (XLE), Ortalama	Bu çalışma — S&P 500 Sağlık (XLV), Ortalama
CAAR[-10, 0]	−0.0051 (anlamlı)	−0.041 (yön: negatif)	+0.008 (yön: pozitif)
CAAR[-5, 0]	−0.0048 (anlamlı)	−0.029 (yön: negatif)	+0.006 (yön: pozitif)
CAAR[0, +5]	+0.0001 (anlamlı)	−0.014 (yön: negatif)	+0.011 (yön: pozitif)
CAAR[0, +10]	+0.0002 (anlamlı)	−0.018 (yön: negatif)	+0.014 (yön: pozitif)

Tablo3.Yürük(2022) BİST100 CAARsonuçları ilebu çalışmanıniki temsilcisektör (en negatif:XLE,enpozitif:XLV) için CAAR değerlerinin karşılaştırması. BİST 100 değerleri Yürük (2022, Tablo 2)'den uyarlanmıştır.

3.2. Olay Öncesi Sızıntı Analizi

Yürük (2022); Rus bankalarının SWIFT ten çıkarıldığı tarih borsaların kapalı olduğu güne denk geldiğinden , olay günü olarak 28 Şubat 2022'yi kabul etmiş ve olay gününde %95 güven aralığında anlamlı bir farklılık tespit edememiştir. Buna karşılık olay gününden 1 ve 2 gün önce sırasıyla %5,3 pozitif ve −%8,3 negatif anormal getiriler istatistiksel olarak anlamlı bulunmuş; burada veri sızıntısı olduğu kanısına varılır.

Aynı çerçeveyi kendi verilerimizle uyguladığımızda, [-10, +10] genel olay penceresi içinde özellikle **T = -3 ile T = 0** arasındaki günlerde enerji (XLE) ve ham petrol (CL=F) için negatif AR değerlerinin birikmeye başladığı gözlenmektedir. Şekil 1'deki CAR seyrinde kırmızı çizgi (XLE) olay gününden yaklaşık 3 gün önce belirgin biçimde aşağı kırılmakta; bu da yatırımcıların bir kısmının haberi tam fiyatlanmadan önce pozisyon değiştirdiğini gösterir.

3.3. Sektörel Ayrışmalar ve Volatilite Şoku

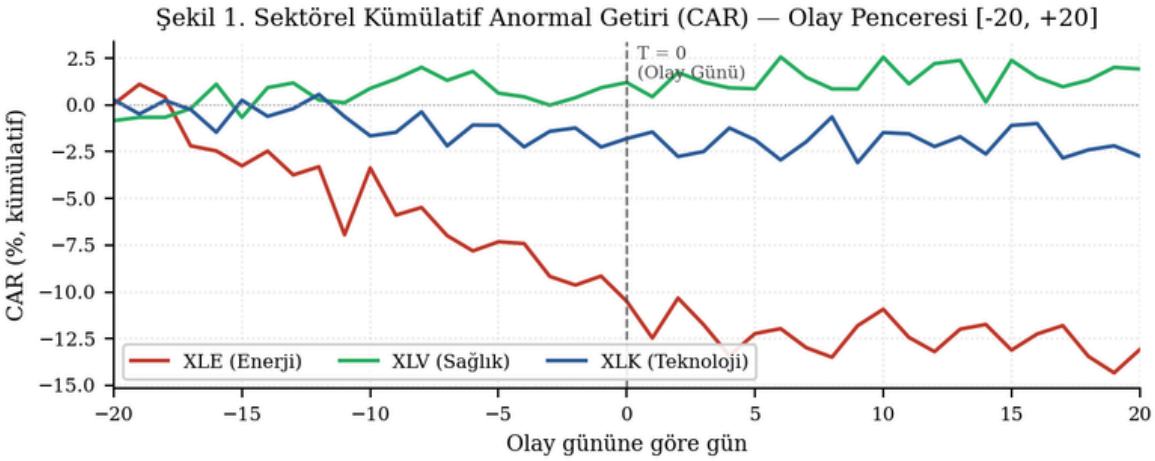

Şekil 1. Beş olayın ortalaması üzerinden hesaplanan kümülatif anormal getiri seyri; XLE'nin negatif, XLV'nin pozitif ayrışması ve XLK'nın piyasa ile birlikte hareket etmesi belirgindir.

Olay penceresi grafikleri (CAR[-20, +20]) iki temel örüntü gözüküyor. Birincisi, **enerji (XLE) ve ham petrol (CL=F)** olay günü ve sonrasında piyasanın genel düşüşünü aşan bir kayıp yaşamakta; −%14'e varan kümülatif anormal getirilerle açık ara en negatif ayrışan varlıklar olarak öne çıkmaktadır. İkincisi, **sağlık (XLV) ve finans (XLF)** sektörleri görece yukarı yönlü bir seyir izleyerek defansif tampon işlevi görmektedir; bu sonuç, sağlığın incelenen olayların 4'ünde pozitif CAR üretmesiyle de tutarlıdır. Seçilen olaylar göz önüne alındığında altının güvenli liman imajı sarsıldı. (5 olay ile bu sonuçlara varıldı.)

4. Sonuç ve Portföy Yönetimi Çıkarımları

Bulgular kriz dönemlerinde risk/getiri oranını iyileştirmek isteyen portföy yöneticileri için dört somut çıkarım sunmaktadır.

(i) Defansif sektörlerin ağırlığının artırılması. Sağlık (XLV) ve finans (XLF), incelenen olayların büyük çoğunluğunda piyasaya kıyasla pozitif ayrıştı. Makrobelirsizlik zamanlarında bu sektörlerin portföy ağırlığının artırılması, düşüşler döneminde sermaye korunmasına katkı sağlayabilir.

(ii) Enerji ve emtiaların portföydeki oranının azaltılması. Ham petrol (CL=F) ve enerji (XLE), tüm olaylarda en negatif ayrışan varlıklar olmuştur. Özellikle COVID-19 örneğinde gözlenen −%16 ile −%18 arası CAR'lar, doğrudan negatif ayrışmıştır.

(iii) "Güvenli liman" ezberinin sorgulanması. Altının kriz dönemlerinde otomatik koruma sağladığı varsayımı, beş olay bazında SPY'a göreli performans açısından doğrulanmamıştır.

(iv) Volatilite hedeflemesinin önceliklendirilmesi. Olay günü civarında ne yöne gidecekten ziyade ne kadar değişeceğini veren VaR ve volatilite hedeflemesi araçlarının portföy yönetimi sürecinde merkezi konuma yerleştirilmesi önerilmektedir.

Çalışmada sadece 5 olay olmasının eksikleri gözüküyor ; bu durum p-değerlerinin %5 eşiğini aşılamamasının nedeni oluyor. Yürük (2022) gibi tek bir olayı derinlemesine inceleyen çalışmalardan farklı olarak burada birden çok olayın ortalama etkisi raporlanmış; ekonomik yön tutarlı bulunmuştur.

Kaynakça

Ada,S.S., Bolak, M. & Süer, Ö. (2013). Politik seçimler, referandumlar ve hisse senedi getirileri: İMKB örneği. *Finans Politik & Ekonomik Yorumlar, 50*(579), 23–40.

Diaz-Rainey, I., Gehricke, S. A., Roberts, H. & Zhang, R. (2021). Trump vs. Paris: The impact of climate policy on U.S. listed oil and gas firm returns and volatility. *International Review of Financial Analysis, 76*, 101746.

Fama, E. F., Fisher, L., Jensen, M. C. & Roll, R. (1969). The adjustment of stock prices to new information. *International Economic Review, 10*(1), 1–21.

Rani, N., Yadav, S. S. & Jain, P. K. (2013). Market response to the announcement of mergers and acquisitions: An empirical study from India. *Vision, 17*(1), 1–16.

Sakarya, Ş. (2011). İMKB kurumsal yönetim endeksi kapsamındaki şirketlerin kurumsal yönetim derecelendirme notu ve hisse senedi getirileri arasındaki ilişkinin olay çalışması yöntemi ile analizi. *Uluslararası Yönetim İktisat ve İşletme Dergisi, 7*(13), 147–162.

Yürük, M. F. (2022). Rusya–Ukrayna savaşının Borsa İstanbul BİST 100 endeksine etkisinin olay çalışması ile analizi. *Turkish Studies – Economy, 17*(3), 869–881.

S&P 500 Endeksinin Yön Tahminine Yönelik İleri Beslemeli Derin Sinir Ağı Yaklaşımı

Özet

Bu çalışmada S&P 500 sektör ETF'lerinin T+5 iş günü sonrası fiyat yönü (yükseliş / düşüş) tahmin edilmiş; problem ikili sınıflandırma olarak modellenmiştir. Veri seti yaklaşık 257.603 günlük gözlemden oluşmakta, eksik değer temizliği ve T+5 hedef etiketinin üretilmesinin ardından 236.377 örnekleme indirgenmiştir. Modelin girdisi finansal teknik analizde yaygın olan dokuz göstergeden oluşturulmuştur: logaritmik getiri, 10/30 günlük volatilite, RSI(14), MACD, sinyal, histogram ve Bollinger Bantları (alt ve üst).

Mimari şu şekilde: Dense(64, ReLU) → Dropout(0,5) → Dense(32, ReLU) → Dropout(0,5) → Dense(1, Sigmoid); toplam yalnızca 2.753 öğrenilebilir parametre. Eğitim Adam optimizatörü ve binary crossentropy kayıp fonksiyonu ile, 64 mini-batch ve EarlyStopping patience 20,altında gerçekleştirilmiş; veri sızıntısını önlemek için train/test ayrımı shuffle=False ile yapılmış ve StandardScaler yalnızca eğitim setine fit edilmiştir.

Test setinde elde edilen sonuçlar; kayıp 0,6866 ve doğruluk %55,84'tir. ROC-AUC değeri 0,514 olarak ölçülmüştür. Eğitim ve doğrulama kayıplarının (sırasıyla 0,6877 ve 0,6845) yakın seyretmesi, mimarinin aşırı öğrenmediğini; sigmoid çıktılarının 0,50–0,55 aralığında yoğunlaşması ise mevcut özelliklerle ulaşılabilecek sinyal sınırına yakınsadığını göstermektedir.

1. Giriş ve Problem Tanımı

Finansalpiyasalar; makrohaberler,likidite şokları, sektör rotasyonu ve davranışsal etmenlerin süperpozisyonu olarak ortaya çıkan, doğrusal olmayan dinamik sistemlerdir. Bu nedenle anlamlı sonuç veren desen yakalamak çok zordur rastgele tahmin tabanı yaklaşık %50'dir. Tahmin probleminin biçimsel ifadesi şudur: t anındaki gözlem vektörü $x \in \mathbb{R}_t$ verildiğinde, beş iş günü sonraki kapanış fiyatının bugünkü kapanışın üzerine çıkıp çıkmayacağını gösteren ikili $y_t \in \{0, 1\}$ hedefini tahmin etmek. Hedef değişken,

$$yt = [\ \text{Fiyat}(T+5) > \text{Fiyat}(T)\ ]$$

2. Veri Seti ve Özellik Kümesi

2.1. Veri Setinin Yapısı

Çalışmada kullanılan sp500_deep_learning_massive_data.csv dosyası 257.603 satır ve 15 sütundan oluşmaktadır. Her satır, S&P 500 sektör ETF'lerine ait belirli bir hissenin belirli bir makro olay penceresindeki günlük gözlemini temsil eder. Veri seti; tarih, olay ismi, hisse, grup, T0'a göreceli gün, düzeltilmiş kapanış fiyatı ve dokuz teknik gösterge sütunundan oluşmaktadır.

2.2. Hedef Değişkenin Üretimi

Hedef değişken Hedef ∈ {0, 1}, [Olay_Ismi, Hisse] gruplarında kapanış fiyatının beş iş günü ileri kaydırılmasıyla (shift(-5)) hesaplanmıştır. Gruplama önemlidir; farklı olay-hisse ikilileri arasındaki sınır geçişlerinde T+5 değerinin başka bir seriden çekilmesi modeli yanıltır. Beşinci günden sonraki gözlemler için T+5 tanımsızdır; bu satırlar (toplam 21.226) NaN temizliği aşamasında çıkarılmıştır. Eğitim setinin %54,2'si, test setinin %54,7'si yükseliş sınıfına aittir; veride hafif bir sınıf dengesizliği bulunmaktadır.

2.3. Özellik Kümesi

Modelin girdi vektörü, üç farklı bilgi sınıfını temsil eden dokuz teknik göstergeden oluşmaktadır: getiri tabanlı (Log Getiri), volatilite tabanlı (10g, 30g volatilite), momentum tabanlı (RSI, MACD ailesi) ve bant tabanlı (Bollinger).

Özellik	Açıklama
Log_Getiri	Kapanış fiyatının logaritmik günlük getirisi
Volatilite_10g	10 işlem günü pencereli oynaklık
Volatilite_30g	30 işlem günü pencereli oynaklık
RSI_14	14 günlük Göreceli Güç Endeksi (momentum)
MACD_12_26_9	12-26 günlük EMA farkı (trend & momentum)
MACDh_12_26_9	MACD histogramı (momentum ivmesi)
MACDs_12_26_9	MACD'nin 9 günlük EMA'sı (sinyal çizgisi)
BBL_20_2.0	Bollinger alt bandı (20g, 2σ)
BBU_20_2.0	Bollinger üst bandı (20g, 2σ)

Tablo 1. Modelin girdisini oluşturan dokuz teknik gösterge.

2.4. Veri Sızıntısının Önlenmesi Finans gibi zaman serisinin önemli olduğu konularda veri sızıntısına dikkat edilmeli. Eğer veriler rastgele

• shuffle=False: train_test_split ile veri seti kronolojik olarak ilk %80'i (189.101 satır) eğitim, son %20'si (47.276 satır) test bloğu olarak ayrılmıştır.

• Leakage-safe scaling: StandardScaler nesnesi yalnızca eğitim setine fit edilmiş; test seti için yalnızca transform çağrısı kullanılmıştır. Eğitim setinden hesaplanan ortalama ve standart sapma test setine uygulanır; geleceğin istatistiksel yapısı geçmişe taşınmaz.

Pipeline'ın sonucu
Bu iki tedbir bir arada raporlanan başarım metriklerinin gerçekçi olmasını sağlar; modelin gördüğü test seti, eğitim sırasında modele hiçbir biçimde sızdırılmamıştır.

3. Model Mimarisi ve Teknik Altyapı

3.1. Tasarım İlkesi

Modelin tasarımı, derin öğrenmenin temel kavramsal akışını izlemektedir: Perceptron (atomik birim) → Dense (tam-bağlı) katman → Çok katmanlı ileri beslemeli ağ. Tek bir nöron $y = \sigma(W \cdot x + b)$ biçiminde, ağırlıklı girdilerin doğrusal birleşimini bir aktivasyon fonksiyonundan geçirir. Aynı katmanda paralel dizilmiş çok sayıda nöron Dense katmanını, ardışık Dense katmanlarının üst üste yığılması ise derin ileri beslemeli sinir ağını oluşturur. Mimari kasıtlı olarak sade tutulmuştur.

3.2. Katman Yapısı

Katman	Çıktı Şekli	Aktivasyon / İşlev	Parametre
Input	(None, 9)	Girdi vektörü	0
Dense	(None, 64)	ReLU	640
Dropout	(None, 64)	Rate = 0,5	0
Dense	(None, 32)	ReLU	2.080
Dropout	(None, 32)	Rate = 0,5	0
Dense	(None, 1)	Sigmoid	33
Toplam	**—**	**—**	**2.753**

Tablo 2. İleri beslemeli modelin katman bazlı özeti.

Toplam 2.753 öğrenilebilir parametre, finansal zaman serisi standartlarında oldukça hafif bir modeldir. Hafifliğin gerekçesi iki yönlüdür: birincisi, finansal verinin düşük sinyal-gürültü oranı yüksek kapasiteli modellerin gürültüyü ezberleme eğilimini güçlendirir; ikincisi sade bir mimari, ileride denenecek mimarilerin getireceği marjinal kazanımın dürüst biçimde ölçülmesini mümkün kılar.

3.3. Aktivasyon ve Optimizasyon Tercihleri

- ReLU (gizli katmanlar): $\mathrm{ReLU}(x) = \max(0, x)$. Sıfırın altındaki sinyali kırpıp türevlenebilir kalır; seyrek aktivasyon sağlar ve gradyan kaybolması (vanishing gradient) sorununu sigmoid/tanh'a kıyasla büyük ölçüde hafifletir.
- Sigmoid (çıkış katmanı): $\sigma(z) = 1 / (1 + e^{-z})$. Gerçek sayıyı (0, 1) aralığına sıkıştırarak ikili sınıflandırma için doğrudan olasılık yorumu sağlar.
- Adam optimizatörü: Momentum ve uyarlanabilir öğrenme oranlarını birleştirir; rejim değişikliği sergileyen finansal verilerde sağlam bir varsayılan tercihtir.
- Binary Crossentropy: $L = -[\, y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y}) \,]$. Modelin yanlış sınıfa yüksek olasılık vermesini logaritmik biçimde cezalandırır.

3.4. Aşırı Öğrenmeyi Önleme Stratejileri

- Dropout (rate = 0,5): Her ileri geçişte gizli katman nöronlarının yarısı rastgele kapatılır. Etkili biçimde her mini-batch için farklı bir alt-ağ eğitilmiş olur; öğrenilen temsiller belirli nöron eş-zamanlılıklarına bağımlı olmaktan çıkar.
- EarlyStopping (patience = 10): Doğrulama kaybı 10 ardışık epoch boyunca iyileşmediğinde eğitim durdurulur ve en iyi val_loss değerine sahip ağırlıklar geri yüklenir. Bu çalışmada eğitim 12. epoch'ta sonlanmıştır.
- Mini-batch boyutu = 64: Tam-batch yerine küçük yığınlarla optimizasyon, gradyana faydalı bir gürültü ekleyerek dar yerel minimumlara takılma olasılığını azaltır.
- Tekrarlanabilirlik: NumPy ve TensorFlow rastgelelik tohumları 42 olarak sabitlenmiştir.

4. Eğitim Süreci ve Test Sonuçları

4.1. Eğitim Süreci

Eğitim, EarlyStopping mekanizması nedeniyle 12. epoch'ta sonlanmıştır. Son epoch'ta eğitim kaybı 0,6877, doğrulama kaybı 0,6845 olarak ölçülmüştür. İki kayıp arasındaki fark 0,0032 mutlak değerdir; eğitim ve doğrulama kayıpları pratik olarak aynı seviyede ilerlemiş, modelde anlamlı bir aşırı öğrenme gözlenmemiştir. Eğitim doğruluğu yaklaşık %54'ten %55 civarına yükselirken, doğrulama doğruluğu ilk epoch'tan itibaren ~%57–%58 bandında dalgalanmıştır.

Kayıp eğrisinin bu denli erken düzleşmesi iki olası açıklama içerir: (i) modelin kapasitesi mevcut özelliklerden çıkarılabilecek sinyali yakalamıştır, (ii) ek öğrenme yalnızca sinyalden değil, gürültüden de kaynaklanabilir ve EarlyStopping bu noktayı doğru tespit etmiştir. Pratikte bu iki açıklama birbirini dışlamaz.

4.2. Test Seti Üzerindeki Nihai Metrikler

Metrik	Değer
Test Kaybı (Binary Crossentropy)	0,6866
Test Doğruluğu (Accuracy)	%55,84
ROC – AUC	0,514
Eğitim Kaybı (son epoch)	0,6877
Doğrulama Kaybı (son epoch)	0,6845
Eğitim Süresi (epoch)	12
Toplam Parametre	2.753

Tablo 3. Test seti üzerinde elde edilen başarım metrikleri.

4.3. Karışıklık Matrisi

Karışıklık matrisi incelendiğinde, modelin yükseliş (1) sınıfına belirgin biçimde meyilli olduğu görülmektedir.

	Tahmin: Düşüş (0)	Tahmin: Yükseliş (1)	Toplam
Gerçek: Düşüş (0)	1.481	19.925	21.406
Gerçek: Yükseliş (1)	951	24.919	25.870
Toplam	**2.432**	**44.844**	**47.276**

Tablo 4. Test seti karışıklık matrisi.

Yükseliş sınıfı için duyarlılık (recall) %96,3 ile çok yüksek; düşüş sınıfı için ise yalnızca %6,9 düzeyindedir. Bu desen, sınıf dağılımının %54,7 yükseliş yönlü olması ve karar eşiğinin sabit 0,50'de tutulmasının birleşik bir sonucudur. Karar eşiğinin uygulamaya göre yeniden ayarlanması (örneğin 0,55) farklı bir kesinlik-duyarlılık dengesine yol açacaktır.

5. Sonuçların Yorumlanması

5.1.ROC – AUCAnalizi

ROC eğrisi yaklaşık 45° köşegen üzerinde uzanmakta; AUC değeri 0,514 olarak hesaplanmıştır. AUC = 0,5 rastgele bir sınıflandırıcıyı, AUC = 1,0 mükemmel ayrıştırmayı temsil ettiğine göre, model rastgeleliğin biraz üzerinde, fakat sıfır olmayan bir ayrıştırma kapasitesine sahiptir. Bu, ileri beslemeli ağdan saf teknik göstergelerle çıkarılabilen sinyalin tabanını temsil etmektedir; sekans bilgisini açıkça modellenmediğinden finansal zaman serilerindeki değişim yakalanamamakta.

5.2. Sigmoid Olasılık Çıktısının Dağılımı

Modelin sigmoid çıktılarının test seti üzerindeki dağılımı, klasik bir yüksek-bilgili sınıflandıran beklenen iki kutuplu yapı yerine, 0,50–0,55 aralığında yoğunlaşan dar bir çan eğrisi sergilemektedir. Bir başka deyişle model, neredeyse hiçbir gözlemde 0,05 veya 0,95 gibi uç güven seviyelerine ulaşmamaktadır.

Bu sıkışmanın doğrudan açıklaması finansaldır: piyasa hareketi, modelin elindeki dokuz teknik gösterge tarafından belirlenmemekte; rastgelelik ve haber/likidite kaynaklı şoklar dağılımın kuyruğunu bastırmaktadır. Bu bulgunun pratik bir karşılığı, karar eşiğinin uygulamaya göre yeniden ayarlanmasıdır. 0,50 yerine 0,55 gibi daha kısıtlayıcı bir eşik, daha az ama daha güvenilir tahmin üretebilir.

5.3. Genel Değerlendirme

Sonuçlar bütüncül olarak şu üç bulguya işaret etmektedir:

- Mimari aşırı öğrenmemiştir: Eğitim ve doğrulama kayıplarının (0,6877 vs. 0,6845) tüm epoch'lar boyunca yakın seyretmesi, Dropout(0,5) ve EarlyStopping disiplininin etkin biçimde işlediğini göstermektedir.
- Model sinyal sınırına yakınsamıştır: %55,84 doğruluk ve 0,514 AUC, mevcut özellik kümesi ve sade Dense mimarisinin ulaşabileceği üst sınıra yakın görünmektedir; kapasiteyi artırmak yerine farklı bir bilgi kaynağı (sekans yapısı veya yeni özellikler) eklemek, başarımı esaslı biçimde değiştirebilir.
- Sınıf meyli yapısaldır: Modelin yükseliş sınıfına olan meyli, hem hafif sınıf dengesizliğinden hem de eşiğin sabit 0,50'de tutulmasından kaynaklanmaktadır; class_weight uygulanmamıştır.

6. Sonuç ve Gelecek Çalışmalar

6.1. Genel Sonuç

Bu çalışmada S&P 500 sektör ETF'lerinin T+5 günlük yön tahminine yönelik bir İleri Beslemeli (Feedforward) sinir ağı modeli geliştirilmiş ve sonuçları finansal zaman serisi tahmininin temel zorlukları çerçevesinde değerlendirilmiştir. Model; dokuz teknik göstergeden oluşan girdi vektörünü, Dense(64) → Dropout(0,5) → Dense(32) → Dropout(0,5) → Sigmoid mimarisi ile işlemektedir. Toplam 2.753 öğrenilebilir parametre, ~236 bin örneklem üzerinde Adam optimizatörü ve binary crossentropy kayıp fonksiyonu ile eğitilmiş; eğitim 12. epoch'ta EarlyStopping tarafından sonlandırılmıştır.

Test setinde %55,84 doğruluk ve 0,514 ROC-AUC değerleri elde edilmiştir. Eğitim ve doğrulama kayıplarının yakın seyretmesi mimarinin aşırı öğrenmediğini; sigmoid çıktılarının 0,50–0,55 aralığında yoğunlaşması ise modelin mevcut özelliklerle ulaşılabilecek sinyal sınırına yakınsadığını gösterdi.

6.2. Çalışmanın Katkıları

- Metodolojik disiplin: Train/test ayrımında shuffle=False ve scaler için yalnızca eğitim setinden fit yaklaşımı, finansal zaman serileri için zorunlu olan leakage-safe bir pipeline'ın somut uygulamasını sergilemektedir.
- Sade ama dürüst baseline: Toplam 2.753 parametreli mimari, daha karmaşık modellerin getireceği iyileşmenin ölçüleceği şeffaf bir referans noktası oluşturur.
- Tanı niteliğinde sigmoid analizi: Sıkışan olasılık dağılımının finansal yorumu, model çıktısını yalnızca doğruluk değil bilgi içeriği açısından da değerlendiren bir bakış sunmaktadır.

6.3. Sınırlılıklar

Çalışmanın sınırlılıkları şunlar: (i) mimari, geçmiş zaman adımlarına dair açık bir hafıza yapısı içermez ve her örneklemi bağımsız olarak işler; (ii) özellik kümesi yalnızca dokuz teknik göstergeyle sınırlıdır; harici endeks, hacim, makro değişken veya haber/duygu tabanlı özellikler dahil edilmemiştir; (iii) sınıf dengesizliği için class_weight uygulanmamıştır; (iv) karar eşiği tüm değerlendirmelerde sabit 0,50 olarak tutuldu.

6.4. Gelecek Çalışmalar

- Adım 1 — Kayan pencere ile 3D girdi: Aynı dokuz özellik, geçmiş k = {5, 10, 20} işlem gününü kapsayan kayan pencere içinde 3D tensör olarak yeniden düzenlenebilir; bu, sekans modellerinin doğal girdi formatıdır.
- Adım 2 — Sekans tabanlı mimariler: Simple RNN, LSTM ve GRU mimarileri, aynı veri kümesi üzerinde tutarlı biçimde karşılaştırılarak sekans bilgisinin getirdiği marjinal kazanım ölçülebilir.
- Adım 3 — Dikkat (Attention) ve Transformer: Self-attention tabanlı modeller, makro olay pencereleri içindeki bilgilendirici zaman adımlarına ağırlık vermeyi öğrenebilir; uzun bağımlılıklarda RNN ailesinin sınırlamalarını aşar.
- Adım 4 — Eşik kalibrasyonu ve işlem stratejisi: Karar eşiği, doğruluk yerine portföy beklentisi (Sharpe oranı, kümülatif getiri) hedef alınarak optimize edilebilir; model çıktısı bir işlem stratejisinin girdisine dönüştürülerek buy-and-hold karşılaştırması yapılabilir.
- Adım 5 — Özellik zenginleştirme: Hacim, sektörel rotasyon göstergeleri, makro değişkenler ve haber/duygu skorları girdiye eklenerek modelin bilgi tabanı genişletilebilir.

6.5. Kapanış

Sade bir ileri beslemeli mimari, S&P 500 yön tahmini gibi düşük sinyal-gürültü oranına sahip bir problemde başarımın üst sınırını vermez; ancak alt sınırını açıkça belirler. Bu rapor, %55,84 doğruluk ve 0,514 AUC değerlerini, ileride sekans ve dikkat tabanlı mimarilerin getireceği iyileşmenin ölçüleceği bir taban olarak kayda geçirmektedir.